

به نام خدا



دانشکده مهندسی کامپیوتر

هوش مصنوعی و سیستم های خبره

پروژه اول (درخت تصمیم)

دکتر آرش عبدی

پاییز ۱۴۰۲

طراحان:

بهاره کاوسی نژاد

فرناز خوش دوست آزاد



- در صورت وجود هرگونه ابهام در سوالات تنها به طراح آن سوال پیام دهید.
- با توجه به تنظیم شدن ددلاین تمارین توسط خود شما امکان تمدید وجود ندارد.
- خوانا و مرتب بنویسید.
- زبان برنامه نویسی دلخواه است. (پیشنهاد: پایتون)
- کل محتوای ارسالی را داخل فایل زیپ قرار داده و نام آن را شماره دانشجویی قرار دهید.
- داک پروژه را واضح و مرتب بنویسید.
- انجام تمرین تک نفره است. لطفا به تنهایی انجام شود، در غیر اینصورت نمره منفی در نظر
- گرفته خواهد شد.

آیدی تلگرام طراحان :

@iAmMafhoot

@HelenAzaad

@Bahareh_0281

پروژه اول هوش مصنوعی و سیستم های خبره: درخت تصمیم

هدف پروژه: پیاده سازی درخت تصمیم با استفاده از آنتروپی و Gini index برای تشخیص کلاهبرداری های پرداخت های مجازی

شرح پروژه:

1. تجزیه و تحلیل مجموعه داده:

با تجزیه و تحلیل مجموعه داده ارائه شده که مربوط به تشخیص کلاهبرداری های پرداخت آنلاین هستند، شروع کنید. featureهای موجود را گسسته سازی کنید، مقادیری که موجود نیستند را با مقداری مناسب جایگزین کنید (و یا می توانید آن سطر را حذف کنید)، مواردی که به صورت عدد نیستند را به عدد تبدیل کنید و ...

برای گسسته سازی ورودی های از نوع پیوسته یا ورودی های دارای مقادیر خیلی زیاد بازه های عددی در نظر بگیرید. یک ایده آن است که بازه مینیمم تا ماکزیمم اعداد در مجموعه آموزشی را به تعدادی بازه مساوی تقسیم کنید و دو بازه اضافی هم برای مقادیر کمتر از مینیمم و بیشتر از ماکزیمم در نظر بگیرید. همچنین میتوانید ایده های دیگری را نیز برای گسسته سازی ورودی های پیوسته ارائه دهید و آنها را امتحان کنید.

2. پیاده سازی الگوریتم درخت تصمیم:

کلاس ها و الگوریتم درخت تصمیم مورد نظر خود را پیاده کنید. اگر در پیاده سازی این الگوریتم خلاقیت و نوآوری داشته باشید، نمره امتیازی خواهد داشت؛ مثلاً الگوریتم شما به صورت تطبیقی (adaptive) باشد (با تشخیص الگوهای کلاهبرداری جدید، خود را به روز رسانی کند) و ...

یک بار الگوریتم خود را با آنتروپی و بار دیگر با استفاده از Gini index پیاده سازی کنید.

3. آموزش درخت تصمیم (training):

درخت تصمیم خود را با استفاده از دیتاستی که در فایل onlinefraud.csv قرار گرفته train کنید. می توانید از 2000 داده اول برای این کار استفاده کنید. در این دیتاست:

- step: نمایانگر واحد زمانی است و هر step به معنای یک ساعت است.
- type: نوع تراکنش آنلاین
- amount: مقدار تراکنش
- nameOrig: کاربر شروع کننده تراکنش
- oldbalanceOrg: موجودی حساب قبل از تراکنش

- newbalanceOrig: موجودی حساب بعد از تراکنش
- nameDest: دریافت کننده در تراکنش
- oldbalanceDest: موجودی دریافت کننده قبل از تراکنش
- newbalanceDest: موجودی دریافت کننده بعد از تراکنش
- isFraud: آیا کلاه برداری است یا خیر

4. ارزیابی مدل:

مدل درخت تصمیم خود را با استفاده از تکنیک های cross-validation ارزیابی کنید و نتایج را نشان دهید. از میان داده هایی که برای test استفاده نکرده اید به صورت تصادفی برای test انتخاب کنید. دقت کنید که بهتر است به تعداد مساوی از نمونه های کلاه برداری و غیر کلاه برداری انتخاب کنید.

5. نمایش درخت تصمیم:

درخت تصمیم خود را نشان دهید. استفاده از کتابخانه های موجود در پایتون برای نمایش بهتر درخت تصمیم و همچنین روند پیشرفت و بهبود درخت در طول زمان، نمره امتیازی خواهد داشت.

6. تحلیل و بررسی نتایج:

درخت تصمیم بر اساس آنتروپی و Gini index را با یکدیگر مقایسه کنید. سعی کنید با استفاده از تکنیک های مختلف درخت تصمیم خود را بهبود بخشید و نتایج به دست آمده را تحلیل کنید. میزان دقت درخت خود را نمایش دهید.

اگر از ایده ی جدیدی در هر قسمت پروژه استفاده کردید (مثلا استفاده از روش جدیدی برای گسسته سازی داده ها)، نشان دهید که این کار چه تغییری در درخت تصمیم شما ایجاد کرده است و آیا باعث بهبود آن شده است یا خیر.

- ✓ خلاقیت شما برای افزایش دقت درخت مثل افزایش داده های آموزشی یا هر گونه انتخاب هوشمندانه از میان آن ها، روش های جدیدتر و حرفه ای تر گسسته سازی و یا حتی فعالیت های اضافه تر حرفه ای مانند تحلیل های آماری جداگانه از فیچر ها، Data cleaning یا Feature engineering و ... می تواند نمره امتیازی داشته باشد.
- ✓ در نظر داشته باشید برای پیاده سازی درخت تصمیم نباید از توابع آماده استفاده کنید. لذا فرمول آنتروپی، Gini index، تابع خود درخت تصمیم (همانند توابع بازگشتی و فرآیند درخت سازی و ...) را باید خودتان پیاده کنید.
- ✓ استفاده از توابع آماده تنها برای بخش های دیگر مانند خواندن اکسل، احیانا نمایش گرافیکی خروجی درخت (در صورت علاقه)، نمایش دقت خروجی و ... بلامانع است.

آنچه تحویل داده می شود:

1. کد اجرایی برنامه با توضیحات لازم برای اجرا
2. درختی که پیدا کرده اید را به هر نحوی که می توانید و قابل فهم باشد باید نشان دهید (با هر پروتکلی که توضیح می دهید باید قابل فهم و توضیحات هر شاخه مشخص باشد).
3. نشان دهید که در هر گره، کدام ویژگی تست می شود، مقدار دست آورد اطلاعات و آنتروپی در زیرشاخه ها چقدر است.
4. گزارش مختصری از مسیر انجام کار و چالش هایی که مواجه شدید، اجراهای گرفته شده و روند پیشرفت پروژه، توضیحاتی در مورد تفاوت دو معیار آنتروپی و Gini index به صورت مختصر و همچنین توضیحاتی در مورد معیار و دقت خود در داده های آزمایشی ارائه دهید! آیا بیش بر ارزش داشته اید؟ ایده ای برای افزایش دقت دارید؟ (حتی اگر پیاده نکرده باشید)
5. هرگونه تحلیل اضافه مفید و خلاقیت 😊 (می تواند نمره امتیازی داشته باشد)